

Índice general

1. Fundamentos del Aprendizaje de Máquina	3
1.1. Introducción	3
1.1.1. Breve perspectiva histórica	3
1.1.2. Los cuatro pilares	4
1.1.3. Una advertencia epistemológica	5
1.1.4. Estructura del capítulo	5
1.2. Notación	5
1.3. Paradigmas de aprendizaje	5
1.3.1. Aprendizaje supervisado	5
1.3.2. Aprendizaje no supervisado	6
1.3.3. Aprendizaje autosupervisado	7
1.3.4. Aprendizaje por refuerzo	7
1.3.5. Otras modalidades	8
1.4. Primer pilar: teoría de generalización	8
1.4.1. El problema del aprendizaje	8
1.4.2. Cotas de generalización y capacidad	9
1.4.3. Sesgo, varianza y compromiso entre ajuste y complejidad	10
1.4.4. Regularización y validación	10
1.4.5. La paradoja de la sobreparametrización	11
1.5. Segundo pilar: aproximación funcional	11
1.5.1. El aprendizaje como aproximación de funciones	11
1.5.2. Teoremas de aproximación universal	12
1.5.3. Balance entre expresividad y eficiencia	12
1.6. Tercer pilar: métodos de optimización	13
1.6.1. El problema de optimización	13
1.6.2. Descenso de gradiente y sus variantes	13
1.6.3. Entrenamiento de redes profundas	14
1.6.4. Geometría de la función de pérdida	14
1.7. Cuarto pilar: representación de datos	15
1.7.1. De características manuales a representaciones aprendidas	15
1.7.2. Propiedades de las buenas representaciones	15
1.7.3. La perspectiva de la teoría de la información	16

1.8. Más allá de las asociaciones: causalidad	16
1.8.1. La crítica de Pearl a la estadística basada en asociaciones	16
1.8.2. El aprendizaje de máquina causal	17
1.9. Resumen del capítulo	18
Lecturas recomendadas	19

Capítulo 1

Fundamentos del Aprendizaje de Máquina

1.1. Introducción

El *aprendizaje de máquina* (*machine learning*) es la rama de la inteligencia artificial que estudia algoritmos capaces de mejorar su desempeño en una tarea a partir de la experiencia, es decir, de los datos, sin que cada situación posible tenga que ser programada de forma explícita. En lugar de seguir reglas codificadas a mano, un sistema de aprendizaje de máquina *infiere* patrones y regularidades a partir de ejemplos y los utiliza para predecir o tomar decisiones sobre casos que no ha observado. Una formulación operativa, ampliamente aceptada en la literatura de texto, establece que un programa aprende de la experiencia E respecto de una tarea T y una medida de desempeño P si su desempeño en T , medido por P , mejora con E (Mitchell, 1997).

1.1.1. Breve perspectiva histórica

La expresión “aprendizaje de máquina” se asocia con Samuel (1959), quien describió un programa para jugar damas que mejoraba su juego compitiendo contra sí mismo. Es frecuente atribuirle la definición del campo como “la capacidad de las computadoras de aprender sin ser programadas explícitamente”; sin embargo, esa frase no aparece textualmente en su artículo y debe tomarse como una paráfrasis posterior de su espíritu. Las raíces de la disciplina son más profundas: el modelo de neurona de McCulloch and Pitts (1943), el perceptrón de Rosenblatt (1958) y la discusión de Turing (1950) sobre máquinas capaces de aprender. Tras períodos de entusiasmo y de “inviernos” de la inteligencia artificial, el área resurgió en las décadas de 1990 y 2000 con las máquinas de vectores de soporte (Cortes and Vapnik, 1995) y los métodos de ensamble, como *bagging* (Breiman, 1996) y *boosting* (Freund

and Schapire, 1997). A partir de 2012, el éxito de las redes convolucionales profundas en reconocimiento visual (Krizhevsky et al., 2012) inició la era del *aprendizaje profundo* (*deep learning*), cuya síntesis puede consultarse en LeCun et al. (2015) y Schmidhuber (2015), y cuyo tratamiento de referencia es Goodfellow et al. (2016).

1.1.2. Los cuatro pilares

El objetivo de este capítulo es establecer los fundamentos teóricos y prácticos sobre los que se construye el aprendizaje de máquina moderno. Para ello se organiza el material en torno a cuatro subtemas que pueden considerarse los *cuatro pilares* de la disciplina:

1. **Teoría de generalización:** ¿por qué un modelo entrenado con un número finito de ejemplos puede predecir correctamente sobre datos que nunca vio? Se discuten el riesgo empírico y el riesgo esperado, las cotas de generalización basadas en la dimensión VC y en la complejidad de Rademacher, y la descomposición sesgo-varianza (Vapnik, 1998; Shalev-Shwartz and Ben-David, 2014; Mohri et al., 2018).
2. **Aproximación funcional:** el aprendizaje como problema de aproximar una función desconocida a partir de muestras ruidosas, y los teoremas de aproximación universal que sustentan la expresividad de las redes neuronales (Cybenko, 1989; Hornik et al., 1989; Barron, 1993).
3. **Métodos de optimización:** los algoritmos que permiten hallar los parámetros del modelo, desde el descenso de gradiente estocástico (Robbins and Monro, 1951; Bottou et al., 2018) hasta sus variantes adaptativas (Kingma and Ba, 2015) y los métodos de segundo orden.
4. **Representación de datos:** la elección y el aprendizaje de las características con las que se describe el mundo, desde la ingeniería de características clásica hasta el aprendizaje de representaciones (Bengio et al., 2013).

Estos pilares no son independientes. La aproximación funcional garantiza que *existe* un buen modelo; la optimización determina si es posible *encontrarlo*; la generalización decide si lo encontrado *sirve* fuera de la muestra; y la representación condiciona cuán fácil es todo lo anterior. Su estudio conjunto es particularmente importante para comprender las *arquitecturas de aprendizaje profundo*. Las redes actuales tienen del orden de millones a cientos de miles de millones de parámetros, es decir, están *sobrep parametrizadas*: poseen más grados de libertad que ejemplos de entrenamiento. Contrario a lo que predice la teoría clásica, estas redes no sobreajustan de forma catastrófica y alcanzan desempeños sobresalientes, en ocasiones superiores a los humanos,

en visión, lenguaje y audio (Zhang et al., 2017; Belkin et al., 2019). Entender cómo se concilian los cuatro pilares con este hecho — mediante conceptos como el sobreajuste benigno, el doble descenso (*double descent*) y la regularización implícita del descenso de gradiente — es hoy uno de los temas de investigación más activos.

1.1.3. Una advertencia epistemológica

La mayor parte de los algoritmos en uso se basa en detectar *asociaciones estadísticas*: correlaciones entre variables que permiten predecir, aunque no necesariamente comprender los mecanismos causales que las producen. Este enfoque puede ser insuficiente cuando se pretende explicar, intervenir sobre un sistema o trasladar el conocimiento a entornos distintos del de entrenamiento. Judea Pearl ha sostenido que no basta con estudiar asociaciones y que se requieren herramientas formales de intervención (el *do-cálculo*) y de razonamiento *contrafactual* (Pearl, 2009, 2019). La adopción de esta perspectiva en el aprendizaje de máquina aún es incipiente, pero su incorporación puede ser decisiva para construir sistemas más robustos, explicables y capaces de operar fuera de la distribución de entrenamiento (Schölkopf et al., 2021). Existen ya avances en esta dirección, como el aprendizaje por refuerzo causal (Zeng et al., 2023), que introduce estructuras causales en la toma de decisiones secuenciales.

1.1.4. Estructura del capítulo

La Sección 1.2 fija la notación. La Sección 1.3 describe los paradigmas de aprendizaje. Las Secciones 1.4 a 1.7 desarrollan, en ese orden, los cuatro pilares. La Sección 1.8 discute la perspectiva causal como horizonte de la disciplina y la Sección 1.9 resume lo esencial. El capítulo cierra con lecturas recomendadas para profundizar.

1.2. Notación

Salvo que se indique lo contrario, se emplea la notación de la Tabla 1.1.

1.3. Paradigmas de aprendizaje

Los paradigmas se distinguen principalmente por el tipo de *señal de retroalimentación* que recibe el algoritmo (Tabla 1.2).

1.3.1. Aprendizaje supervisado

En el aprendizaje supervisado se dispone de pares entrada-salida $\{(x_i, y_i)\}_{i=1}^n$, donde y_i es la *etiqueta* del ejemplo x_i , y el objetivo es aprender una función f

Cuadro 1.1: Notación utilizada en el capítulo.

Símbolo	Significado
$\mathcal{X}, \mathcal{Y}$	Espacios de entrada y de salida
$P(x, y)$	Distribución (desconocida) que genera los datos
$S = \{(x_i, y_i)\}_{i=1}^n$	Muestra de entrenamiento, i.i.d. según P
$\mathcal{H}$	Clase de hipótesis
f, f_θ	Predictor; predictor con parámetros $\theta \in \mathbb{R}^p$
$\ell(f(x), y)$	Función de pérdida
$R(f), \hat{R}(f)$	Riesgo esperado y riesgo empírico
η, B, λ	Tasa de aprendizaje, tamaño de minibatch, coeficiente de regularización

Cuadro 1.2: Paradigmas de aprendizaje según la señal disponible.

Paradigma	Señal	Ejemplos de tareas
Supervisado	Etiquetas y_i	Clasificación, regresión
No supervisado	Ninguna (estructura)	Agrupamiento, estimación de densidad
Autosupervisado	Pseudo-etiquetas derivadas de los datos	Modelos de lenguaje, aprendizaje de representaciones
Por refuerzo	Recompensas	Control, juegos, alineamiento de valores

que prediga la etiqueta de ejemplos nuevos. Según la naturaleza de la salida se distinguen dos problemas fundamentales:

- **Clasificación:** la salida pertenece a un conjunto finito de categorías, $y \in \{1, \dots, K\}$. Ejemplos: reconocimiento de dígitos, detección de correo no deseado, apoyo al diagnóstico médico.
- **Regresión:** la salida es un valor continuo, $y \in \mathbb{R}$. Ejemplos: predicción de precios o estimación de temperaturas.

Entre los algoritmos clásicos destacan la regresión lineal y logística, los árboles de decisión, las máquinas de vectores de soporte (Cortes and Vapnik, 1995) y las redes neuronales; una exposición sistemática se encuentra en Hastie et al. (2009) y Bishop (2006). El aprendizaje supervisado ha sido el paradigma dominante en las aplicaciones industriales, pero su limitación es evidente: exige datos etiquetados, cuya obtención es costosa y con frecuencia requiere conocimiento experto.

1.3.2. Aprendizaje no supervisado

En el aprendizaje no supervisado solo se dispone de las entradas $\{x_i\}_{i=1}^n$, y el objetivo es descubrir la estructura subyacente de los datos. Sus tareas principales son:

- **Agrupamiento** (*clustering*): particionar los datos en grupos de elementos similares (K-medias, agrupamiento jerárquico, mezclas de gaussianas).
- **Reducción de dimensionalidad**: obtener una representación compacta que preserve la información relevante (análisis de componentes principales, t-SNE, autocodificadores).
- **Estimación de densidad**: modelar la distribución $p(x)$ que generó los datos, lo que permite además generar muestras nuevas.

1.3.3. Aprendizaje autosupervisado

El aprendizaje autosupervisado ocupa una posición intermedia y ha transformado el aprendizaje profundo reciente. Consiste en generar *pseudo-etiquetas* a partir de los propios datos, sin intervención humana, y entrenar al modelo en una tarea auxiliar (*pretext task*) cuya solución obliga a aprender representaciones útiles. Ejemplos representativos son:

- **Modelos de lenguaje**: predecir la palabra siguiente o palabras enmascaradas en un texto, como en BERT (Devlin et al., 2019) y GPT (Brown et al., 2020), ambos basados en la arquitectura Transformer (Vaswani et al., 2017).
- **Aprendizaje contrastivo**: aprender representaciones en las que dos versiones perturbadas de una misma imagen queden cerca y las de imágenes distintas queden lejos, como en SimCLR (Chen et al., 2020) o CLIP (Radford et al., 2021).

El modelo preentrenado suele *ajustarse finamente* (*fine-tuning*) con una cantidad comparativamente pequeña de datos etiquetados y alcanza desempeños superiores a los del entrenamiento supervisado directo. Este esquema explica en gran medida el éxito de los *modelos fundacionales* (Bommasani et al., 2021), cuyo desempeño mejora de forma predecible con el tamaño del modelo, de los datos y del cómputo (Kaplan et al., 2020).

1.3.4. Aprendizaje por refuerzo

En el aprendizaje por refuerzo, un *agente* interactúa con un *entorno* en una secuencia de pasos: en cada estado s_t elige una acción a_t , recibe una *recompensa* r_t y transita a un nuevo estado. El objetivo es aprender una *política* $\pi(a | s)$ que maximice el retorno esperado descontado:

$$G_t(\pi) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \right], \quad (1.1)$$

donde $\gamma \in [0, 1)$ es el factor de descuento. A diferencia del caso supervisado, no existe un supervisor que indique la acción correcta: el agente debe *explorar*, evaluar las consecuencias de sus acciones y resolver el problema de asignación de crédito (*credit assignment*) hacia decisiones lejanas en el tiempo. Formalmente, el problema suele modelarse como un proceso de decisión de Markov, y el valor de una política satisface la ecuación de Bellman,

$$Q^\pi(s, a) = \mathbb{E}[r_t + \gamma Q^\pi(s_{t+1}, a_{t+1}) \mid s_t = s, a_t = a]. \quad (1.2)$$

Los métodos fundacionales incluyen Q-learning (Watkins and Dayan, 1992) y los métodos de gradiente de política (Williams, 1992); la referencia estándar es Sutton and Barto (2018). En aprendizaje profundo destacan DQN (Mnih et al., 2015), AlphaGo (Silver et al., 2016) y los modelos de lenguaje alineados mediante retroalimentación humana (RLHF; Christiano et al., 2017; Ouyang et al., 2022).

1.3.5. Otras modalidades

Merecen mención el **aprendizaje semisupervisado**, que combina pocos datos etiquetados con muchos sin etiquetar (Chapelle et al., 2006); el **aprendizaje por transferencia**, que reutiliza conocimiento de un dominio en otro (Pan and Yang, 2010); y el **aprendizaje activo**, en el que el modelo elige qué ejemplos solicitar a un oráculo para su etiquetado (Settles, 2009).

1.4. Primer pilar: teoría de generalización

1.4.1. El problema del aprendizaje

El aprendizaje supervisado se formaliza como un problema de minimización de riesgo. Existe una distribución desconocida $P(x, y)$ sobre los datos y una *función de pérdida* $\ell(f(x), y)$ que mide el error de la predicción $f(x)$. Se busca f en una clase de hipótesis $\mathcal{H}$ que minimice el *riesgo esperado* (o *riesgo verdadero*):

$$R(f) = \mathbb{E}_{(x,y) \sim P} [\ell(f(x), y)]. \quad (1.3)$$

Como P es desconocida, $R(f)$ no puede calcularse. En la práctica se minimiza el *riesgo empírico* sobre la muestra de entrenamiento:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i). \quad (1.4)$$

El principio de minimización del riesgo empírico (ERM, por sus siglas en inglés) (Vapnik, 1998) es la piedra angular del aprendizaje de máquina, pero plantea la pregunta central de este pilar: *¿cuándo garantiza la minimización del riesgo empírico una buena generalización?* Conviene definir la *brecha de*

generalización $R(f) - \hat{R}(f)$, cuya magnitud es precisamente lo que las cotas de esta sección buscan controlar.

Una advertencia previa es el teorema de “no hay almuerzo gratis”: promediado sobre todos los problemas posibles, ningún algoritmo supera a otro (Wolpert, 1996). El aprendizaje solo es posible si se introducen *supuestos* sobre el problema, ya sea restringiendo $\mathcal{H}$ o preferiendo ciertas hipótesis dentro de ella; a este conjunto de supuestos se le llama *sesgo inductivo*.

1.4.2. Cotas de generalización y capacidad

La teoría de aprendizaje estadístico de Vapnik y Chervonenkis (Vapnik and Chervonenkis, 1971; Vapnik, 1998) y el marco PAC de Valiant (1984) responden mediante *cotas de generalización*. Para una clase $\mathcal{H}$ de dimensión VC igual a d y una pérdida acotada en $[0, 1]$, con probabilidad al menos $1 - \delta$ sobre la muestra se cumple, para toda $f \in \mathcal{H}$,

$$R(f) \leq \hat{R}(f) + \sqrt{\frac{d \left(\ln \frac{2n}{d} + 1 \right) + \ln \frac{4}{\delta}}{n}}. \quad (1.5)$$

La dimensión VC mide la *capacidad* de la clase: es el mayor número de puntos que $\mathcal{H}$ puede clasificar de todas las maneras posibles (“pulverizar”). La intuición es clara: para generalizar, la capacidad del modelo debe ser acorde con el tamaño de la muestra; un modelo demasiado complejo *sobreajusta* (*overfitting*), memorizando la muestra en lugar de capturar la regularidad subyacente.

Una alternativa que depende de la distribución de los datos es la *complejidad de Rademacher*. Si ℓ toma valores en $[0, 1]$, con probabilidad al menos $1 - \delta$,

$$R(f) \leq \hat{R}(f) + 2\mathfrak{R}_n(\ell \circ \mathcal{H}) + \sqrt{\frac{\ln(1/\delta)}{2n}}, \quad (1.6)$$

donde $\mathfrak{R}_n(\ell \circ \mathcal{H}) = \mathbb{E}_{S, \sigma} \left[\sup_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i \ell(f(x_i), y_i) \right]$ y los σ_i son variables aleatorias independientes uniformes en $\{-1, +1\}$ (Bartlett and Mendelson, 2002; Mohri et al., 2018). Esta medida cuantifica cuánto puede la clase ajustarse a ruido aleatorio. Una tercera familia, la de las cotas PAC-bayesianas (McAllester, 1999), mide la complejidad por la distancia entre una distribución *a posteriori* sobre hipótesis y una *a priori*, y ha producido las primeras cotas no triviales para redes profundas (Dziugaite and Roy, 2017).

Observación 1.1. Las cotas (1.5) y (1.6) son de *peor caso* y, en redes profundas, suelen resultar vacuas (mayores que 1) si se usa la dimensión VC, que crece con el número de parámetros. Cotas que dependen de normas de las matrices de pesos y de los márgenes, en lugar del número de parámetros, son más informativas (Bartlett et al., 2017).

1.4.3. Sesgo, varianza y compromiso entre ajuste y complejidad

Una perspectiva complementaria es la descomposición sesgo-varianza (Geman et al., 1992). Sea $y = f^*(x) + \varepsilon$ con $f^*(x) = \mathbb{E}[y \mid x]$, $\mathbb{E}[\varepsilon] = 0$ y $\text{Var}(\varepsilon) = \sigma^2$, y sea $\hat{f}_S$ el predictor entrenado con la muestra aleatoria S . Para la pérdida cuadrática, el error esperado en un punto x se descompone como

$$\mathbb{E}_{S,\varepsilon}[(\hat{f}_S(x) - y)^2] = \underbrace{(\mathbb{E}_S[\hat{f}_S(x)] - f^*(x))^2}_{\text{sesgo}^2} + \underbrace{\mathbb{E}_S[(\hat{f}_S(x) - \mathbb{E}_S[\hat{f}_S(x)])^2]}_{\text{varianza}} + \underbrace{\sigma^2}_{\text{ruido irreducible}}. \quad (1.7)$$

El sesgo refleja cuán lejos queda, en promedio, el predictor de la función verdadera; la varianza, cuánto cambia el predictor al variar la muestra. Los modelos simples tienen alto sesgo y baja varianza; los complejos, lo contrario. Clásicamente, el diseño de un buen sistema consiste en equilibrar ambos términos, lo que da lugar a la conocida curva en forma de “U” del error de prueba frente a la complejidad (Hastie et al., 2009). Esta descomposición es específica de la pérdida cuadrática; para otras pérdidas existen generalizaciones, pero no son tan limpias.

1.4.4. Regularización y validación

La regularización agrupa las técnicas que controlan la complejidad *efectiva* del modelo para mejorar la generalización:

- **Regularización explícita:** penalizaciones en el objetivo, como la norma ℓ_2 (*ridge*; Hoerl and Kennard, 1970) o ℓ_1 (*lasso*; Tibshirani, 1996), o técnicas estocásticas como *dropout* (Srivastava et al., 2014).
- **Regularización implícita:** el propio algoritmo de optimización actúa como regularizador. Por ejemplo, el descenso de gradiente inicializado en cero sobre mínimos cuadrados subdeterminados converge a la solución de mínima norma ℓ_2 , y sobre datos separables con pérdida logística converge en dirección al clasificador de máximo margen (Soudry et al., 2018).
- **Validación:** reservar un subconjunto de datos para seleccionar hiperparámetros y detener el entrenamiento a tiempo (*early stopping*; Prechelt, 1998). Cuando los datos son escasos se recurre a la validación cruzada (Hastie et al., 2009).

Un principio metodológico esencial es mantener un conjunto de *prueba* que no intervenga en ninguna decisión de diseño; de lo contrario, la estimación del error de generalización resulta optimista.

1.4.5. La paradoja de la sobreparametrización

Los modelos profundos modernos tienen muchos más parámetros que datos de entrenamiento y pueden interpolar exactamente la muestra (riesgo empírico nulo), incluso cuando las etiquetas se reemplazan por ruido aleatorio (Zhang et al., 2017). La teoría clásica asocia esa situación con sobreajuste; sin embargo, estas arquitecturas obtienen buenos resultados en datos de prueba, a menudo *mejores* que los de modelos más pequeños. Este fenómeno se describe mediante la curva de *doble descenso* (Belkin et al., 2019; Nakkiran et al., 2021): al aumentar la capacidad del modelo, el error de prueba primero sigue la curva clásica en “U”, alcanza un máximo cerca del *umbral de interpolación* (donde el número de parámetros es del orden del número de datos) y luego *vuelve a descender* en el régimen sobreparametrizado.

Se han propuesto varias explicaciones complementarias. La teoría del *sobreajuste benigno* identifica condiciones — por ejemplo, un espectro de covarianza con muchas direcciones de baja varianza — bajo las cuales un interpolador de mínima norma generaliza bien (Bartlett et al., 2020). La *regularización implícita* del descenso de gradiente sesga la búsqueda hacia soluciones simples (Soudry et al., 2018). Finalmente, la dinámica de entrenamiento en redes muy anchas puede describirse con el *núcleo tangente neuronal* (Jacot et al., 2018). Ninguna de estas explicaciones es todavía completa para las redes profundas de uso práctico, y el problema sigue abierto; vuelve a poner en el centro a los cuatro pilares de este capítulo.

1.5. Segundo pilar: aproximación funcional

1.5.1. El aprendizaje como aproximación de funciones

Desde esta perspectiva, el aprendizaje supervisado consiste en aproximar una función desconocida $f^* : \mathcal{X} \rightarrow \mathcal{Y}$, posiblemente observada con ruido, $y = f^*(x) + \varepsilon$, a partir de muestras finitas. Las clases de hipótesis más utilizadas son:

- **Modelos lineales:** $f(x) = w^\top x + b$; simples, interpretables y eficientes. Combinados con una transformación fija $\phi(x)$ (Sección 1.7) pueden representar relaciones no lineales.
- **Árboles y ensambles:** particionan el espacio de entrada y combinan muchos predictores débiles (bosques aleatorios, *gradient boosting*; Breiman, 1996; Freund and Schapire, 1997).
- **Redes neuronales:** composiciones de funciones simples no lineales,

$$f_\theta(x) = W_L \sigma(W_{L-1} \sigma(\cdots \sigma(W_1 x + b_1) \cdots) + b_{L-1}) + b_L, \quad (1.8)$$

donde σ es una función de activación no lineal y $\theta = \{W_\ell, b_\ell\}_{\ell=1}^L$.

1.5.2. Teoremas de aproximación universal

Los teoremas de aproximación universal establecen la expresividad de las redes neuronales.

Teorema 1.1 (Aproximación universal; Cybenko, 1989; Hornik et al., 1989; Leshno et al., 1993). *Sea σ una función continua no polinomial, $K \subset \mathbb{R}^d$ compacto y $g : K \rightarrow \mathbb{R}$ continua. Para todo $\varepsilon > 0$ existen $m \in \mathbb{N}$, $a_j, b_j \in \mathbb{R}$ y $w_j \in \mathbb{R}^d$ tales que*

$$\sup_{x \in K} \left| g(x) - \sum_{j=1}^m a_j \sigma(w_j^\top x + b_j) \right| < \varepsilon.$$

Cybenko demostró el resultado para activaciones sigmoidales, Hornik y colaboradores lo extendieron a clases más generales (Hornik et al., 1989; Hornik, 1991) y Leshno et al. (1993) mostraron que la no polinomialidad de σ es condición necesaria y suficiente. Existen también versiones para redes profundas de anchura acotada (Lu et al., 2017).

Estos teoremas son resultados de *existencia*: garantizan que hay una red que aproxima bien a g , pero no dicen cómo *encontrarla* (materia del pilar de optimización), cuántas neuronas m se necesitan ni cuántos datos hacen falta (materia de generalización y representación). Barron (1993) acotó la tasa para funciones con un primer momento de Fourier finito: el error cuadrático medio de una red de una capa con m neuronas decae como $\mathcal{O}(1/m)$, *independientemente de la dimensión d* de la entrada, aunque la constante puede depender de d . Esta interdependencia entre los pilares es precisamente lo que hace interesante y difícil el aprendizaje de máquina.

1.5.3. Balance entre expresividad y eficiencia

No toda función que *puede* aproximarse puede aproximarse *eficientemente*. Para ciertas familias de funciones, las redes profundas requieren exponencialmente menos neuronas que las superficiales: Telgarsky (2016) construye funciones representables por redes de profundidad $\Theta(k^3)$ que no pueden aproximarse con redes de profundidad $\mathcal{O}(k)$ salvo con un número exponencial de nodos, y Eldan and Shamir (2016) exhiben una función de la que ocurre algo análogo entre redes de dos y de tres capas. Para funciones *composicionales* — aquellas que se expresan como jerarquías de funciones de pocas variables — las redes profundas evitan la *maldición de la dimensionalidad* que sufren las superficiales (Poggio et al., 2017). Esto ofrece una justificación teórica de la eficacia de la profundidad en imágenes, texto y audio, cuyas regularidades son jerárquicas y composicionales. Conviene subrayar, no obstante, que estos resultados son de *separación* sobre familias específicas de funciones, no una demostración de que los datos reales posean tal estructura.

1.6. Tercer pilar: métodos de optimización

1.6.1. El problema de optimización

Fijada una familia paramétrica f_θ , hallar el mejor modelo se reduce a un problema de optimización:

$$\theta^* \in \arg \min_{\theta} \hat{R}(\theta) + \lambda \Omega(\theta), \quad (1.9)$$

donde $\Omega(\theta)$ es un término de regularización y $\lambda \geq 0$ controla su peso. Este problema es, en general, no convexo y de muy alta dimensión, lo que impide aplicar directamente los métodos clásicos de optimización convexa (Nocedal and Wright, 2006) y ha motivado algoritmos específicos (Bottou et al., 2018).

1.6.2. Descenso de gradiente y sus variantes

El descenso de gradiente (GD) itera

$$\theta_{t+1} = \theta_t - \eta \nabla \hat{R}(\theta_t), \quad (1.10)$$

con paso η (tasa de aprendizaje). Si $\hat{R}$ es convexa y L -suave, GD con $\eta \leq 1/L$ satisface $\hat{R}(\theta_t) - \hat{R}^* = \mathcal{O}(1/t)$; si además es fuertemente convexa, la convergencia es lineal (Nocedal and Wright, 2006; Bottou et al., 2018). El costo de calcular el gradiente completo es prohibitivo con grandes volúmenes de datos, por lo que se emplea el **descenso de gradiente estocástico** (SGD) (Robbins and Monro, 1951), que usa el gradiente sobre un minibatch aleatorio $\mathcal{B}_t$ de tamaño B :

$$\theta_{t+1} = \theta_t - \eta \frac{1}{B} \sum_{i \in \mathcal{B}_t} \nabla_{\theta} \ell(f_{\theta}(x_i), y_i). \quad (1.11)$$

El gradiente del minibatch es un estimador insesgado del gradiente completo. Su ruido, lejos de ser solo un inconveniente, actúa como regularización y ayuda a escapar de puntos silla y de mínimos agudos; además, la razón entre la tasa de aprendizaje y el tamaño del minibatch gobierna una “temperatura” efectiva del entrenamiento (Smith and Le, 2018). Se ha observado que lotes muy grandes tienden a converger a mínimos más agudos con peor generalización (Keskar et al., 2017), aunque este efecto puede mitigarse ajustando la tasa de aprendizaje (Goyal et al., 2017).

Las variantes dominantes incorporan memoria de gradientes pasados y adaptación por coordenada:

- **Momentum** (Polyak, 1964): $v_{t+1} = \mu v_t + g_t$, $\theta_{t+1} = \theta_t - \eta v_{t+1}$, donde g_t es el gradiente estocástico y $\mu \in [0, 1)$.

- **Métodos adaptativos:** Adagrad (Duchi et al., 2011) escala el paso por coordenada según el historial de gradientes. Adam (Kingma and Ba, 2015) combina momentum con normalización por una media móvil de cuadrados:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad \theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}, \quad (1.12)$$

donde $\hat{m}_t, \hat{v}_t$ son versiones corregidas de sesgo. AdamW (Loshchilov and Hutter, 2019) desacopla el decaimiento de pesos del gradiente adaptativo y es hoy la opción estándar para entrenar Transformers.

- **Métodos de segundo orden y geometría:** el método de Newton y sus aproximaciones (BFGS, gradiente conjugado) usan información de curvatura (Nocedal and Wright, 2006); el *gradiente natural* (Amari, 1998) emplea la métrica de Fisher del modelo, y K-FAC y métodos relacionados la aproximan a escala; véase Martens (2020). Su costo computacional ha limitado su uso frente a los métodos de primer orden.

1.6.3. Entrenamiento de redes profundas

Las redes profundas se entrenan calculando gradientes con la *retropropagación* (*backpropagation*), que aplica eficientemente la regla de la cadena (Rumelhart et al., 1986). Su entrenamiento presenta desafíos específicos:

- **Gradientes que desaparecen o explotan** en redes profundas o recurrentes (Bengio et al., 1994). Se mitigan con activaciones como ReLU, inicializaciones adecuadas (Glorot and Bengio, 2010; He et al., 2015), normalización por lotes (Ioffe and Szegedy, 2015) y conexiones residuales (He et al., 2016).
- **Sensibilidad a la tasa de aprendizaje:** se atenúa con programas de la tasa de aprendizaje (*learning rate schedules*), reinicios cíclicos (Loshchilov and Hutter, 2017) y fases de calentamiento (*warm-up*).
- **Costo de ajuste en modelos grandes:** técnicas de ajuste eficiente en parámetros, como la adaptación de bajo rango (LoRA; Hu et al., 2022), permiten adaptar modelos preentrenados entrenando solo una fracción mínima de sus parámetros. Esta técnica concierne al *ajuste fino* y no a la inestabilidad del entrenamiento.

1.6.4. Geometría de la función de pérdida

Aunque la pérdida de una red profunda no es convexa, el entrenamiento por SGD funciona sorprendentemente bien. Varios resultados ayudan a entenderlo. En dimensión alta, los puntos críticos problemáticos son sobre todo

puntos silla y no mínimos locales malos (Dauphin et al., 2014), y en ciertos modelos los mínimos locales tienen valores cercanos al óptimo global (Choromanska et al., 2015). La visualización de paisajes de pérdida muestra que las conexiones residuales los vuelven más suaves (Li et al., 2018). En el régimen sobreparametrizado, el descenso de gradiente converge a mínimos globales con pérdida de entrenamiento nula, bajo condiciones de anchura suficiente (Du et al., 2019); en términos generales, esto se debe a que la pérdida satisface una condición de tipo Polyak–Łojasiewicz, $\frac{1}{2}\|\nabla \hat{R}(\theta)\|^2 \geq \mu(\hat{R}(\theta) - \hat{R}^*)$, que implica convergencia lineal (Bottou et al., 2018). Estas garantías se demuestran en regímenes idealizados (redes muy anchas), por lo que su alcance a las arquitecturas prácticas es parcial.

1.7. Cuarto pilar: representación de datos

1.7.1. De características manuales a representaciones aprendidas

Todo algoritmo de aprendizaje opera sobre una *representación* de los datos, es decir, una transformación $\phi: \mathcal{X} \rightarrow \mathcal{Z}$ hacia un espacio de características. Durante décadas, el éxito de un sistema dependió de la *ingeniería de características* (*feature engineering*): bolsas de palabras en texto, histogramas de gradientes orientados en visión (Dalal and Triggs, 2005), descriptores invariantes a escala como SIFT (Lowe, 2004). Los métodos de *kernel* permiten trabajar con representaciones implícitas de dimensión muy alta sin calcularlas explícitamente, a través de una función $k(x, x') = \langle \phi(x), \phi(x') \rangle$ (Schölkopf and Smola, 2002); el teorema del representante garantiza que la solución de muchos problemas regularizados es una combinación de $k(\cdot, x_i)$ (Schölkopf et al., 2001).

El aprendizaje profundo cambió el paradigma: las representaciones se *aprenden* conjuntamente con la tarea. Esta idea se conoce como *aprendizaje de representaciones* (*representation learning*) y es la base conceptual del aprendizaje profundo, según la revisión de Bengio et al. (2013). Las capas sucesivas construyen representaciones jerárquicas: de píxeles a bordes, de bordes a texturas y de texturas a partes de objetos. En lenguaje, las representaciones distribuidas de palabras capturan regularidades semánticas (Mikolov et al., 2013).

1.7.2. Propiedades de las buenas representaciones

Según Bengio et al. (2013), una buena representación debería:

- **Desenredar los factores de variación:** separar las fuentes independientes de variación (iluminación, identidad del objeto, pose). Se han propuesto objetivos para fomentar esta propiedad (Higgins et al.,

2017), aunque, sin sesgos inductivos o supervisión adicional, el desenredado no es identificable en general (Locatello et al., 2019).

- **Ser suficiente pero compacta:** preservar la información relevante para la tarea sin redundancia.
- **Permitir transferencia:** generalizar a tareas y dominios relacionados (Pan and Yang, 2010).
- **Ser robusta:** mantenerse estable ante perturbaciones irrelevantes de la entrada.

1.7.3. La perspectiva de la teoría de la información

La teoría de la información (Cover and Thomas, 2006) ofrece herramientas para razonar sobre las representaciones. El principio InfoMax propone maximizar la información mutua entre la entrada y la representación (Linsker, 1988). El principio del *cuello de botella de información* busca representaciones Z que sean mínimas y suficientes para predecir Y (Tishby et al., 1999):

$$\min_{p(z|x)} I(X; Z) - \beta I(Z; Y), \quad (1.13)$$

con $\beta > 0$; su aplicación a redes profundas (Tishby and Zaslavsky, 2015; Shwartz-Ziv and Tishby, 2017) ha sido objeto de debate empírico y teórico (Saxe et al., 2019). En aprendizaje contrastivo, la pérdida InfoNCE maximiza una cota inferior de la información mutua entre vistas del mismo dato (van den Oord et al., 2018; Hjelm et al., 2019):

$$\mathcal{L}_{\text{InfoNCE}} = -\mathbb{E} \left[\log \frac{\exp(s(z_i, z_i^+)/\tau)}{\sum_{j=1}^N \exp(s(z_i, z_j)/\tau)} \right], \quad (1.14)$$

donde s mide similitud, τ es una temperatura y z_i^+ es la representación de una vista del mismo ejemplo. Métodos como Barlow Twins (Zbontar et al., 2021) logran representaciones informativas mediante el principio de *reducción de redundancia*, sin requerir ejemplos negativos. La escala de datos y de modelos ha mostrado que las representaciones aprendidas por tareas autosupervisadas se transfieren notablemente bien a tareas posteriores (Bommasani et al., 2021), de modo que la representación es, quizá, el producto más valioso del entrenamiento.

1.8. Más allá de las asociaciones: causalidad

1.8.1. La crítica de Pearl a la estadística basada en asociaciones

Pearl (2009); Pearl and Mackenzie (2018) ha argumentado que la mayoría de los métodos de aprendizaje de máquina opera únicamente en el primer

peldaño de su *escalera de la causalidad*:

1. **Asociación** ($P(y | x)$): ¿qué indica x sobre y ? Es el nivel de la estadística y del aprendizaje supervisado.
2. **Intervención** ($P(y | \text{do}(x))$): ¿qué ocurriría si *hiciéramos* $X = x$?
3. **Contrafactuales**: ¿habría ocurrido y si x hubiera sido distinto, dado que lo observado fue otra cosa?

La diferencia entre observar e intervenir es fundamental: $P(y | x) \neq P(y | \text{do}(x))$ en general, pues la primera se ve afectada por *confusores*, variables que influyen tanto en X como en Y (la paradoja de Simpson es un ejemplo clásico). La teoría formaliza estas preguntas con modelos causales estructurales y grafos dirigidos acíclicos (DAG) (Pearl, 1995), donde cada variable se genera como $X_i := f_i(\text{Pa}_i, U_i)$, con Pa_i sus causas directas y U_i un término de ruido exógeno. Sus dos herramientas centrales son:

- El **do-cálculo**: reglas de inferencia para manipular distribuciones de intervención y, bajo condiciones de identificabilidad, reducirlas a cantidades observacionales. Un caso particular es el *ajuste por puerta trasera*: si un conjunto Z bloquea todos los caminos de puerta trasera entre X y Y ,

$$P(y | \text{do}(x)) = \sum_z P(y | x, z) P(z). \quad (1.15)$$

- El razonamiento **contrafactual**, que se evalúa en tres pasos — abducción (inferir U a partir de lo observado), acción (modificar el modelo) y predicción — y resulta fundamental para explicar, asignar responsabilidad y comprender el comportamiento de los sistemas.

Un modelo puramente asociacional puede fallar de forma catastrófica ante cambios de distribución y no puede fundamentar decisiones de intervención ni explicaciones (Pearl, 2019; Schölkopf et al., 2021). Cabe señalar que esta posición no es unánime: los métodos actuales muestran capacidades de generalización notables sin estructura causal explícita, y la identificación de efectos causales exige supuestos (como el conocimiento del DAG) que no siempre pueden verificarse con datos.

1.8.2. El aprendizaje de máquina causal

La integración de la causalidad en el aprendizaje de máquina es un campo en crecimiento que incluye:

- **Descubrimiento causal**: aprender la estructura causal a partir de datos, con métodos basados en restricciones, en puntuación o en modelos funcionales (Spirtes et al., 2000; Peters et al., 2017).

- **Inferencia causal:** estimar el efecto de intervenciones a partir de datos observacionales, en el marco de resultados potenciales (Rubin, 1974). Incluye meta-aprendices como el T-learner y el X-learner (Künzel et al., 2019) y el aprendizaje automático doblemente robusto o *debiased* (DML; Chernozhukov et al., 2018). Un parámetro habitual es el efecto promedio del tratamiento, $ATE = \mathbb{E}[Y(1) - Y(0)]$.
- **Robustez y transferencia:** usar estructura causal para obtener modelos que generalicen fuera de la distribución de entrenamiento, como en el aprendizaje de invarianzas (Arjovsky et al., 2019) y en el aprendizaje de representaciones causales (Schölkopf et al., 2021).
- **Aprendizaje por refuerzo causal:** incorporar DAG causales en el aprendizaje por refuerzo, tanto para modelar la dinámica del entorno como para permitir la evaluación fuera de política y razonamientos contrafactuales; un caso temprano es el de bandidos con confusores no observados (Bareinboim et al., 2015), y una revisión reciente puede verse en Zeng et al. (2023). Los trabajos del área reportan políticas más robustas y mejor transferencia entre entornos, aunque a menudo en entornos controlados y bajo supuestos sobre la estructura causal.

Aunque hoy la mayor parte de los sistemas desplegados se apoya en asociaciones estadísticas, es plausible que la teoría de Pearl cobre importancia creciente, en particular en dominios de alto riesgo (salud, justicia, sistemas autónomos), donde predecir no basta: hay que intervenir y explicar.

1.9. Resumen del capítulo

- El aprendizaje de máquina busca algoritmos que mejoran con la experiencia; la expresión se asocia con el trabajo de Samuel (1959).
- Cuatro pilares sostienen la disciplina: teoría de generalización, aproximación funcional, métodos de optimización y representación de datos; están profundamente interrelacionados.
- Los paradigmas se distinguen por la señal de retroalimentación: etiquetas (supervisado), estructura (no supervisado), pseudo-etiquetas (autosupervisado) y recompensas (refuerzo).
- La generalización se estudia con cotas basadas en la dimensión VC, la complejidad de Rademacher y el enfoque PAC-bayesiano, y con la descomposición sesgo-varianza.
- Las redes sobreparametrizadas desafían la teoría clásica y exhiben doble descenso y sobreajuste benigno; explicarlo requiere revisar los cuatro pilares.

- La aproximación universal garantiza la expresividad de las redes, y los resultados de separación respaldan el papel de la profundidad.
- El descenso de gradiente estocástico y sus variantes adaptativas son el motor del entrenamiento, y su ruido y sesgo implícito contribuyen a la generalización.
- Las representaciones aprendidas, en particular mediante autosupervisión, son el producto central del aprendizaje profundo moderno.
- La teoría de la causalidad de Pearl propone superar las asociaciones estadísticas mediante el do-cálculo y el razonamiento contrafactual, con avances en inferencia causal y aprendizaje por refuerzo causal.

Lecturas recomendadas

Para una introducción general, [Murphy \(2022\)](#) y [Bishop \(2006\)](#); para teoría de generalización, [Shalev-Shwartz and Ben-David \(2014\)](#) y [Mohri et al. \(2018\)](#); para aprendizaje profundo, [Goodfellow et al. \(2016\)](#); para optimización a gran escala, [Bottou et al. \(2018\)](#); para el fenómeno del doble descenso y el sobreajuste benigno, [Belkin et al. \(2019\)](#) y [Bartlett et al. \(2020\)](#); para causalidad, [Pearl \(2009\)](#), [Peters et al. \(2017\)](#) y la presentación divulgativa de [Pearl and Mackenzie \(2018\)](#); y para la relación entre causalidad y aprendizaje de representaciones, [Schölkopf et al. \(2021\)](#).

Bibliografía

- Shun-ichi Amari. Natural gradient works efficiently in learning. *Neural Computation*, 10(2):251–276, 1998.
- Martin Arjovsky, Léon Bottou, Ishaan Gulrajani, and David Lopez-Paz. Invariant risk minimization. Technical Report 1907.02893, arXiv, 2019.
- Elias Bareinboim, Andrew Forney, and Judea Pearl. Bandits with unobserved confounders: A causal approach. In *Advances in Neural Information Processing Systems 28*, pages 1342–1350, 2015.
- Andrew R. Barron. Universal approximation bounds for superpositions of a sigmoidal function. *IEEE Transactions on Information Theory*, 39(3):930–945, 1993.
- Peter L. Bartlett and Shahar Mendelson. Rademacher and gaussian complexities: Risk bounds and structural results. *Journal of Machine Learning Research*, 3:463–482, 2002.
- Peter L. Bartlett, Dylan J. Foster, and Matus Telgarsky. Spectrally-normalized margin bounds for neural networks. In *Advances in Neural Information Processing Systems 30*, pages 6240–6249, 2017.
- Peter L. Bartlett, Philip M. Long, Gábor Lugosi, and Alexander Tsigler. Benign overfitting in linear regression. *Proceedings of the National Academy of Sciences*, 117(48):30063–30070, 2020.
- Mikhail Belkin, Daniel Hsu, Siyuan Ma, and Soumik Mandal. Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proceedings of the National Academy of Sciences*, 116(32):15849–15854, 2019.
- Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2):157–166, 1994.
- Yoshua Bengio, Aaron Courville, and Pascal Vincent. Representation learning: A review and new perspectives. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(8):1798–1828, 2013.

- Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- Rishi Bommasani et al. On the opportunities and risks of foundation models. Technical Report 2108.07258, arXiv, 2021.
- Léon Bottou, Frank E. Curtis, and Jorge Nocedal. Optimization methods for large-scale machine learning. *SIAM Review*, 60(2):223–311, 2018.
- Leo Breiman. Bagging predictors. *Machine Learning*, 24(2):123–140, 1996.
- Tom B. Brown et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems 33*, pages 1877–1901, 2020.
- Olivier Chapelle, Bernhard Schölkopf, and Alexander Zien. *Semi-Supervised Learning*. MIT Press, 2006.
- Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *PMLR*, pages 1597–1607, 2020.
- Victor Chernozhukov et al. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1):C1–C68, 2018.
- Anna Choromanska, Mikael Henaff, Michael Mathieu, Gérard Ben Arous, and Yann LeCun. The loss surfaces of multilayer networks. In *Proceedings of the 18th International Conference on Artificial Intelligence and Statistics (AISTATS)*, volume 38 of *PMLR*, pages 192–204, 2015.
- Paul F. Christiano et al. Deep reinforcement learning from human preferences. In *Advances in Neural Information Processing Systems 30*, pages 4299–4307, 2017.
- Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.
- Thomas M. Cover and Joy A. Thomas. *Elements of Information Theory*. Wiley, 2 edition, 2006.
- George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.
- Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 1, pages 886–893, 2005.

- Yann N. Dauphin, Razvan Pascanu, Caglar Gulcehre, Kyunghyun Cho, Surya Ganguli, and Yoshua Bengio. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization. In *Advances in Neural Information Processing Systems 27*, pages 2933–2941, 2014.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.
- Simon S. Du, Jason D. Lee, Haochuan Li, Liwei Wang, and Xiyu Zhai. Gradient descent finds global minima of deep neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *PMLR*, pages 1675–1685, 2019.
- John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12:2121–2159, 2011.
- Gintare Karolina Dziugaite and Daniel M. Roy. Computing nonvacuous generalization bounds for deep (stochastic) neural networks with many more parameters than training data. In *Proceedings of the 33rd Conference on Uncertainty in Artificial Intelligence (UAI)*, 2017.
- Ronen Eldan and Ohad Shamir. The power of depth for feedforward neural networks. In *Proceedings of the 29th Conference on Learning Theory (COLT)*, volume 49 of *PMLR*, pages 907–940, 2016.
- Yoav Freund and Robert E. Schapire. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*, 55(1):119–139, 1997.
- Stuart Geman, Elie Bienenstock, and René Doursat. Neural networks and the bias/variance dilemma. *Neural Computation*, 4(1):1–58, 1992.
- Xavier Glorot and Yoshua Bengio. Understanding the difficulty of training deep feedforward neural networks. In *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)*, volume 9 of *PMLR*, pages 249–256, 2010.
- Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- Priya Goyal et al. Accurate, large minibatch SGD: Training ImageNet in 1 hour. Technical Report 1706.02677, arXiv, 2017.
- Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2 edition, 2009.

- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 1026–1034, 2015.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- Irina Higgins et al. β -VAE: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations (ICLR)*, 2017.
- R. Devon Hjelm et al. Learning deep representations by mutual information estimation and maximization. In *International Conference on Learning Representations (ICLR)*, 2019.
- Arthur E. Hoerl and Robert W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.
- Kurt Hornik. Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2):251–257, 1991.
- Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- Edward J. Hu et al. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022.
- Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 of *PMLR*, pages 448–456, 2015.
- Arthur Jacot, Franck Gabriel, and Clément Hongler. Neural tangent kernel: Convergence and generalization in neural networks. In *Advances in Neural Information Processing Systems 31*, pages 8571–8580, 2018.
- Jared Kaplan et al. Scaling laws for neural language models. Technical Report 2001.08361, arXiv, 2020.
- Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, and Ping Tak Peter Tang. On large-batch training for deep learning: Generalization gap and sharp minima. In *International Conference on Learning Representations (ICLR)*, 2017.

- Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.
- Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems 25*, pages 1097–1105, 2012.
- Sören R. Künnel, Jasjeet S. Sekhon, Peter J. Bickel, and Bin Yu. Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the National Academy of Sciences*, 116(10):4156–4165, 2019.
- Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.
- Moshe Leshno, Vladimir Ya. Lin, Allan Pinkus, and Shimon Schocken. Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. *Neural Networks*, 6(6):861–867, 1993.
- Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. In *Advances in Neural Information Processing Systems 31*, pages 6389–6399, 2018.
- Ralph Linsker. Self-organization in a perceptual network. *Computer*, 21(3):105–117, 1988.
- Francesco Locatello et al. Challenging common assumptions in the unsupervised learning of disentangled representations. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *PMLR*, pages 4114–4124, 2019.
- Ilya Loshchilov and Frank Hutter. SGDR: Stochastic gradient descent with warm restarts. In *International Conference on Learning Representations (ICLR)*, 2017.
- Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- David G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110, 2004.
- Zhou Lu, Hongming Pu, Feicheng Wang, Zhiqiang Hu, and Liwei Wang. The expressive power of neural networks: A view from the width. In *Advances in Neural Information Processing Systems 30*, pages 6232–6240, 2017.
- James Martens. New insights and perspectives on the natural gradient method. *Journal of Machine Learning Research*, 21(146):1–76, 2020.

- David A. McAllester. PAC-Bayesian model averaging. In *Proceedings of the 12th Annual Conference on Computational Learning Theory (COLT)*, pages 164–170, 1999.
- Warren S. McCulloch and Walter Pitts. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5(4): 115–133, 1943.
- Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. Technical Report 1301.3781, arXiv, 2013.
- Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- Volodymyr Mnih et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar. *Foundations of Machine Learning*. MIT Press, 2 edition, 2018.
- Kevin P. Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, 2022.
- Preetum Nakkiran, Gal Kaplun, Yamini Bansal, Tristan Yang, Boaz Barak, and Ilya Sutskever. Deep double descent: Where bigger models and more data hurt. *Journal of Statistical Mechanics: Theory and Experiment*, 2021 (12):124003, 2021.
- Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer, 2 edition, 2006.
- Long Ouyang et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems 35*, pages 27730–27744, 2022.
- Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2010.
- Judea Pearl. Causal diagrams for empirical research. *Biometrika*, 82(4): 669–688, 1995.
- Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, 2 edition, 2009.
- Judea Pearl. The seven tools of causal inference, with reflections on machine learning. *Communications of the ACM*, 62(3):54–60, 2019.

- Judea Pearl and Dana Mackenzie. *The Book of Why: The New Science of Cause and Effect*. Basic Books, 2018.
- Jonas Peters, Dominik Janzing, and Bernhard Schölkopf. *Elements of Causal Inference: Foundations and Learning Algorithms*. MIT Press, 2017.
- Tomaso Poggio, Hrushikesh Mhaskar, Lorenzo Rosasco, Brando Miranda, and Qianli Liao. Why and when can deep—but not shallow—networks avoid the curse of dimensionality: A review. *International Journal of Automation and Computing*, 14(5):503–519, 2017.
- Boris T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 4(5):1–17, 1964.
- Lutz Prechelt. Early stopping — but when? In *Neural Networks: Tricks of the Trade*, volume 1524 of *Lecture Notes in Computer Science*, pages 55–69. Springer, 1998.
- Alec Radford et al. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *PMLR*, pages 8748–8763, 2021.
- Herbert Robbins and Sutton Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951.
- Frank Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6):386–408, 1958.
- Donald B. Rubin. Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5):688–701, 1974.
- David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- Arthur L. Samuel. Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development*, 3(3):210–229, 1959.
- Andrew M. Saxe et al. On the information bottleneck theory of deep learning. *Journal of Statistical Mechanics: Theory and Experiment*, 2019(12):124020, 2019.
- Jürgen Schmidhuber. Deep learning in neural networks: An overview. *Neural Networks*, 61:85–117, 2015.

- Bernhard Schölkopf and Alexander J. Smola. *Learning with Kernels*. MIT Press, 2002.
- Bernhard Schölkopf, Ralf Herbrich, and Alexander J. Smola. A generalized representer theorem. In *Computational Learning Theory (COLT/EuroCOLT)*, volume 2111 of *Lecture Notes in Computer Science*, pages 416–426. Springer, 2001.
- Bernhard Schölkopf et al. Toward causal representation learning. *Proceedings of the IEEE*, 109(5):612–634, 2021.
- Burr Settles. Active learning literature survey. Technical Report 1648, University of Wisconsin–Madison, 2009.
- Shai Shalev-Shwartz and Shai Ben-David. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, 2014.
- Ravid Shwartz-Ziv and Naftali Tishby. Opening the black box of deep neural networks via information. Technical Report 1703.00810, arXiv, 2017.
- David Silver et al. Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.
- Samuel L. Smith and Quoc V. Le. A Bayesian perspective on generalization and stochastic gradient descent. In *International Conference on Learning Representations (ICLR)*, 2018.
- Daniel Soudry, Elad Hoffer, Mor Shpigel Nacson, Suriya Gunasekar, and Nathan Srebro. The implicit bias of gradient descent on separable data. *Journal of Machine Learning Research*, 19(70):1–57, 2018.
- Peter Spirtes, Clark Glymour, and Richard Scheines. *Causation, Prediction, and Search*. MIT Press, 2 edition, 2000.
- Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014.
- Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.
- Matus Telgarsky. Benefits of depth in neural networks. In *Proceedings of the 29th Conference on Learning Theory (COLT)*, volume 49 of *PMLR*, pages 1517–1539, 2016.
- Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1):267–288, 1996.

- Naftali Tishby and Noga Zaslavsky. Deep learning and the information bottleneck principle. In *IEEE Information Theory Workshop (ITW)*, pages 1–5, 2015.
- Naftali Tishby, Fernando C. Pereira, and William Bialek. The information bottleneck method. In *Proceedings of the 37th Annual Allerton Conference on Communication, Control, and Computing*, pages 368–377, 1999.
- Alan M. Turing. Computing machinery and intelligence. *Mind*, 59(236):433–460, 1950.
- Leslie G. Valiant. A theory of the learnable. *Communications of the ACM*, 27(11):1134–1142, 1984.
- Aäron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding. Technical Report 1807.03748, arXiv, 2018.
- Vladimir N. Vapnik. *Statistical Learning Theory*. Wiley, 1998.
- Vladimir N. Vapnik and Alexey Ya. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and Its Applications*, 16(2):264–280, 1971.
- Ashish Vaswani et al. Attention is all you need. In *Advances in Neural Information Processing Systems 30*, pages 5998–6008, 2017.
- Christopher J. C. H. Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8(3–4):279–292, 1992.
- Ronald J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3–4):229–256, 1992.
- David H. Wolpert. The lack of a priori distinctions between learning algorithms. *Neural Computation*, 8(7):1341–1390, 1996.
- Jure Zbontar, Li Jing, Ishan Misra, Yann LeCun, and Stéphane Deny. Barlow twins: Self-supervised learning via redundancy reduction. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *PMLR*, pages 12310–12320, 2021.
- Yan Zeng, Ruichu Cai, Fuchun Sun, Libo Huang, and Zhifeng Hao. A survey on causal reinforcement learning. Technical Report 2302.05209, arXiv, 2023.
- Chiyuan Zhang, Samy Bengio, Moritz Hardt, Benjamin Recht, and Oriol Vinyals. Understanding deep learning requires rethinking generalization. In *International Conference on Learning Representations (ICLR)*, 2017.